

葛超

代码仓库: <https://github.com/RudyGo8>

个人博客: <https://blog.grover.top/>

男 | 中共党员 | 18225707015 | 上海 杭州

gechao.work@outlook.com



专业技能

开发框架: 熟悉 FastAPI、Django、Vue, 具备 RESTful API 设计与前后端分离开发经验

大模型应用: 熟悉 LangChain、LangGraph, 掌握 RAG 检索增强、Prompt、Tool Calling、Agent 开发

模型与检索: 了解 Transformer 基础原理, 熟悉 LoRA 微调流程, 掌握向量检索及 Milvus 向量库使用

工程化能力: 熟悉 Docker、Linux、Git、Jenkins CI/CD、Redis, 具备 Playwright 自动化与 MCP 工具接入经验

教育经历

上海工程技术大学 (硕士)

人工智能

2026.06 毕业

池州学院 (本科)

计算机科学与技术

2023.06 毕业

GPA: 3.4 / 4.0 | 专业排名 top 10% | 国家励志奖学金 | CET-4

相关课程: Java开发、Web技术与应用、计算机网络、数据结构、机器学习、人工智能及其应用、最优化方法、矩阵论、自动化

实习经历

运去哪物流科技集团有限公司

AI应用实习生

2025.08 - 2025.12

- 参与内部智能体 RAG 知识库建设, 主要负责探索检索模块迭代优化。采用 **Dense+Sparse 混合检索** 解决单路检索兼顾语义与关键词命中的问题; 在内部标注评测集500+条上, Precision@5 指标提升约 6%; 文档解析模块设计**父子分块检索策略**优化页级父块和片段级子块, 采用候选召回 Top2K - 字块命中 - **父块 Auto-merge** 策略, 将 Recall@5 提升至 90%.
- 主导 Playwright + Pytest** 搭建海外仓 WMS 自动化交互框架, 实现分层 PO架构、Excel **数据驱动**、多环境切换服务器Docker 部署, 并结合 **Jenkins**、Allure、消息通知打通自动执行与结果反馈闭环, 提升业务流程自动化与回归验证效率提升 60%.

上海马帮科技有限公司

python开发实习生

2025.01 - 2025.08

- 负责马帮ERP3.0 刊登模块商品上架升级迭代业务, 设计 **Two-Step** 类目匹配 workflow, 引导多模态模型 **Qwen-2.5-VL** 结合商品图片和标题生成三级类目路径; 通过 **Prompt** 优化, 将类目 Top1 准确率提升至 95%+; 引用 **Embedding** 向量化结合**Hybrid Retrieval** - 关键词匹配与语义相似度通过 RRF算法召回 Top K, 有效提升类目映射准确性, 降低类目体系差异带来的匹配偏差.
- 基于 **Pydantic** 完成接口强校验与 **Schema** 规范化, 落地 Prompt/模型数据库配置化, 实现可扩展、可复用的生成策略.
- 设计**异步任务架构 task_id + 状态机**, A/B 同环境压测将接口首响应 P95 降低约 63%, 服务吞吐提升约 **40%**. 并通过任务查询与前台渐进轮询机制提升任务可追踪性.
- 引入 **Redis TTL** 缓存类目结果 + Embedding 向量, 通过命中复用减少重复推理, 单任务平均 token 消耗下降约 **15%**.
- 基于 **SFT** 数据工程与 **LoRA** 多适配器策略, 构建跨境电商多站点 (Shopee/TikTok/Amazon) 风格化生成能力, 实现商品标题、描述与属性自动生成; 结合 scene + task_type **动态路由**提升生成一致性与复用效率, 并显著降低推理成本.

项目经历

TraceAgentic RAG —— 多步自主知识智能体

<https://github.com/RudyGo8/TraceAgentic.git>

- 设计并实现具备自主迭代检索 RAG 系统, 通过 LangGraph 驱动 Agent 完成多步规划、Grade 评估、查询重写与扩展检索链路.
- 基于 Milvus 向量库实现 **Offline** 文档**父子分块**构建混合索引库和 **Online** 用户query 通过**混合检索**并 **RRF** 融合精排召回.
- 实现会话**长短期 Memory** 机制, 利用Redis、MySQL 持久化、上下文**压缩摘要**方法, 在保证多轮上下文连续性的同时控制长会话 token 开销. 设计 **MCP Gateway** 统一管理多协议远程 MCP 服务, JSON 声明式配置驱动, 实现工具热插拔机制.
- 基于 **SSE** 实现LLM回答的分段流式返回, 实时输出检索进度 rag_step 与完整溯源信息 Trace, 有效降低幻觉并大幅提升系统可解释性. 引入 RAGAS + LangSmith 构建 RAG自动化离线评测与在线监控双闭环, 核心指标从 85% 提升至 92%.

基于 RAG 与 Multi-Agent 电商导购助手

- 设计基于 LangGraph **Manager-Worker** 编排的多 Agent 电商导购系统. 引入 **ReAct + Reflection** 机制构建 Multi-Agent 体系, 实现对业务内容的深度推理; 采用层次化**长上下文 Memory** 架构, 实现多轮对话上下文保持、历史语义记忆动态召回.
- 采用**分层式风险治理**策略, 构建 Rule Engine + LLM Judge + **Human-in-the-Loop** 三级合规审查, 自动化执行放行、脱敏、拦截或人工介入; 在自建电商客服评测集中高风险场景识别 Recall@10 达到 0.93, 整体高风险内容拦截率提升至 95%+.
- 针对单一向量检索在专有名词匹配上不足, 设计 **BM25 + Embedding** 混合检索策略; 支持基于内容哈希文档**增量更新机制**.

科研成果

【会议】第一作者 《Solving the Traveling Salesman Problem Using Graph Attention and Reinforcement Learning》 ICCPR 2025

(EI Compendex / Scopus收录)

【数学建模】华为杯第二十二届中国研究生数学建模竞赛三等奖